

Let there be light

Shoya Matsumori, Takuma Seno, Yuki Abe, Toshiki Ishikawa

WBAI Hackathon 2018


*God said, "Let there be light";
and there was light.*

Genesis 1.3



チーム概要

Keio University



Imai laboratory



松森 匠哉 (M1)



妹尾 卓磨 (M1)



阿部 佑樹 (B4)



石川 敬規 (B4)

Abstract

Proposal

教師なし学習器 β -VAEと予測誤差を用いた
Oculomotor Learning Architecture

- ①: Disentangleな特徴量の獲得
- ②: 予測誤差を用いたサリエンシーの取得
- ③: 予測誤差を用いたタスクスイッチング

Experiment

本ハッカソンにて提供されたOculomotor Taskを解き
分析を行った

本ハッカソンの課題

What?

脳機能及びコネクション的制約をもとに眼球運動タスクを解く

- 構造的特徴
 - FEFでのlikelihood + BGでのthreshold に基づくActionの選択
- タスク的特徴
 - ワーキングメモリの必要性
 - タスクスイッチングの必要性
 - サリエンシー・アテンション獲得の必要性

方針

Policy

Functionally General: ヒューリスティクス排除, 深層学習の利用

Biologically Plausible: Oculomotor Loopの遵守

Computationally Simple: シングルモデル, マルチタスク対応

提案 Proposal

Proposal

教師なし学習器 β -VAEと予測誤差を用いた
Oculomotor Learning Architecture

提案手法はOculomotor Loopに則り([Biologically Plausible](#))

- 予測誤差を用いたサリエンシーの取得
 - ヒューリスティクス排除([Functionally General](#))
- 予測誤差を用いたタスクスイッチング
 - シングルモデル, マルチタスクを実現([Computationally Simple](#))

を実現することが期待できる.

背景: β -VAE [Higgins14, 17]

- 教師なし学習
- VAEの正則化項を $\beta (> 0)$ に拡張
- Disentangleな特徴量抽出が可能

Loss Function

$$\mathcal{L} \equiv E_{q_{\phi}(z|x)} [\log q_{\theta}(x|z)] - \beta D_{\text{KL}}(q_{\phi}(z|x) || p(z))$$

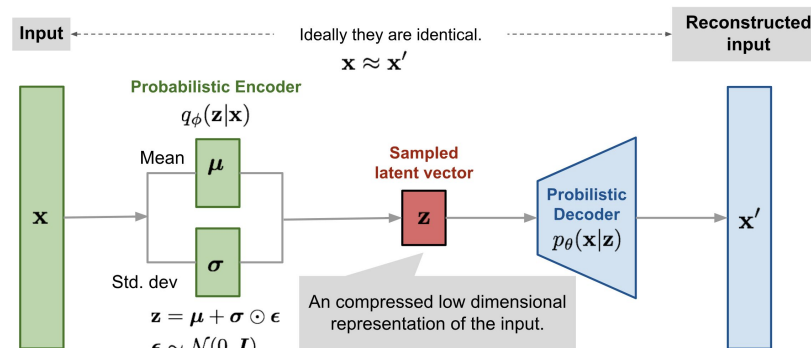
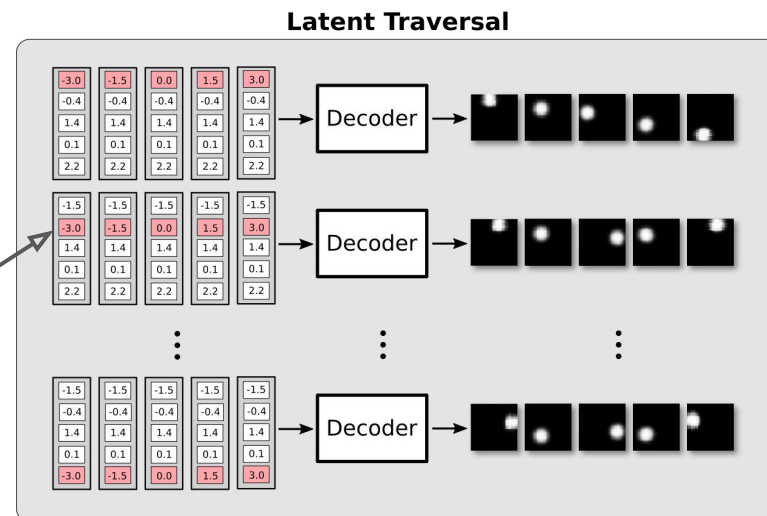
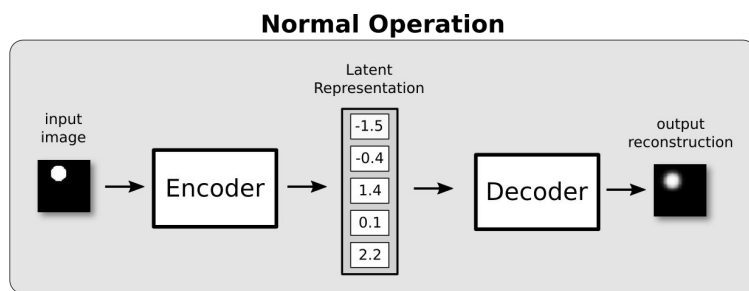


fig. β -VAE




disentangleな特徴量

事前実験: disentangleな特徴量の獲得


- β の値を変化させることでdisentangleな特徴量を獲得できる
(通常のVAEは $\beta=1$)

$$\mathcal{L} \equiv E_{q_{\phi}(z|x)} [\log q_{\theta}(x|z)] - \beta D_{\text{KL}}(q_{\phi}(z|x) || p(z))$$

$\beta = 1$: 色の変化と形の変化が混在している




$\beta = 10$: 色の変化と形の変化が分離できている




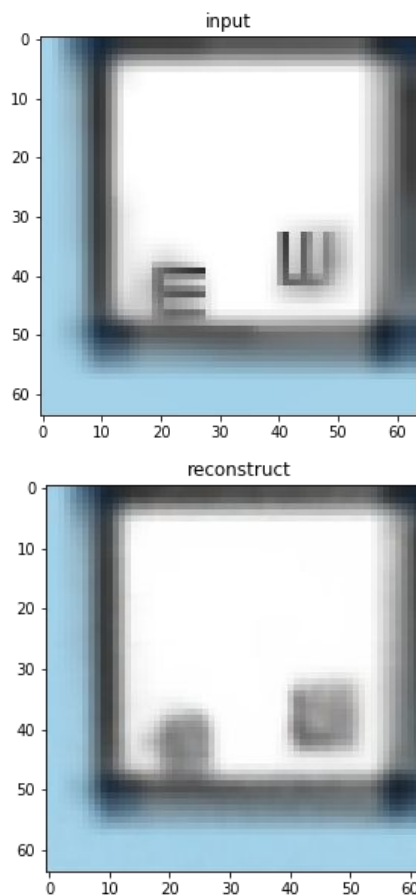
事前実験: β -VAE (latent size = 4)

disentangleに特徴を捉えることができる

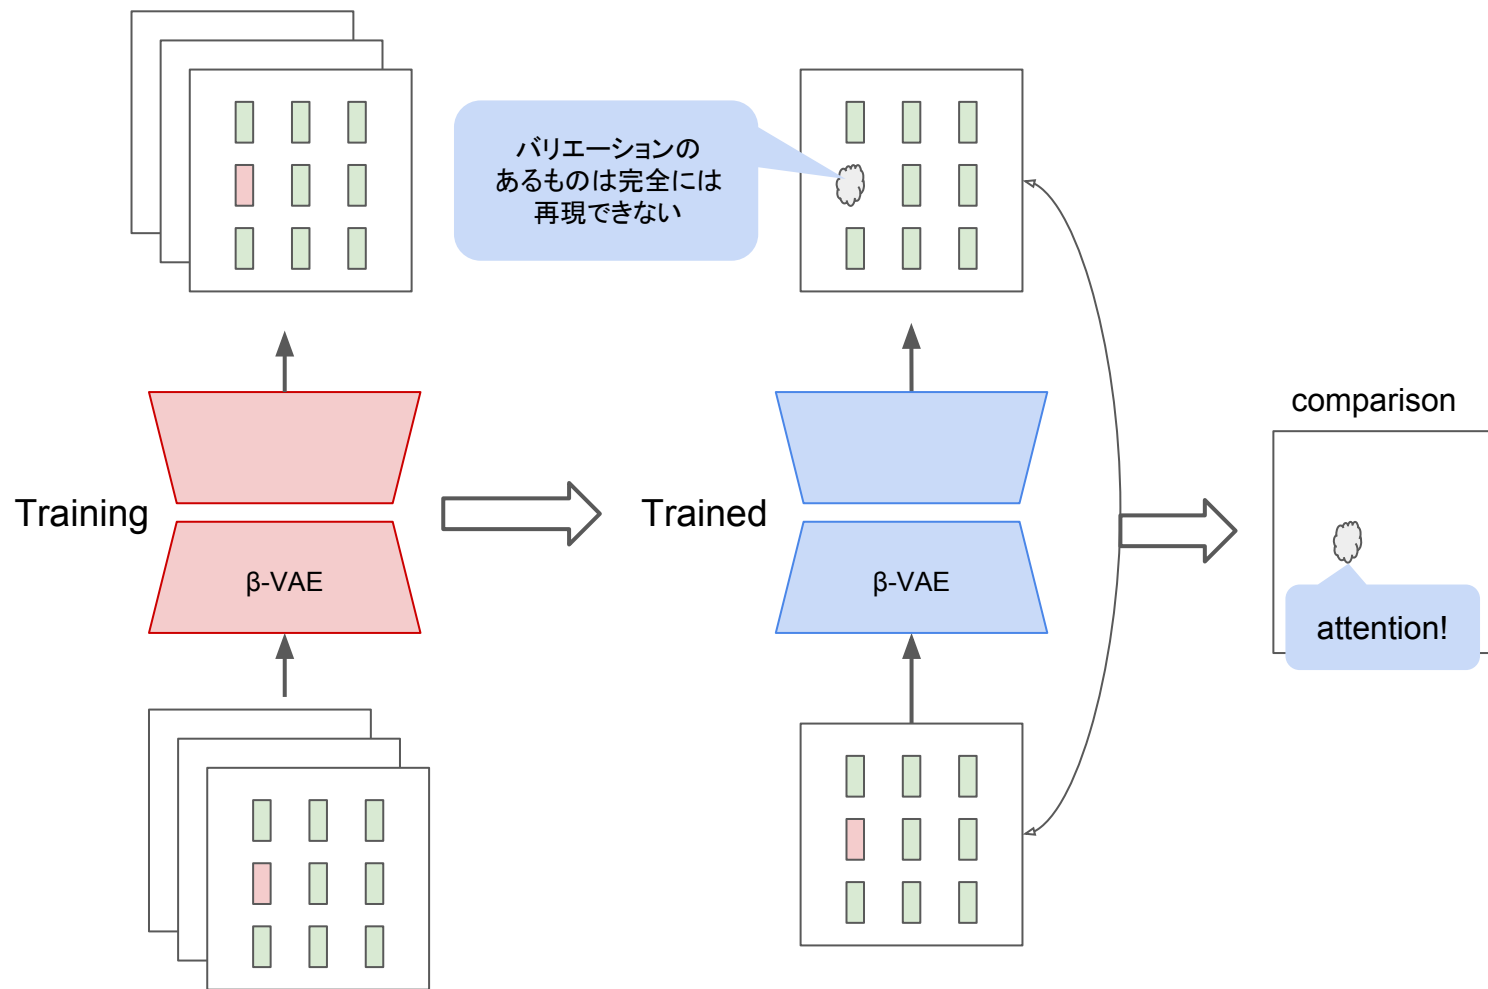


事前実験: β -VAE (latent size = 8, egocentric)

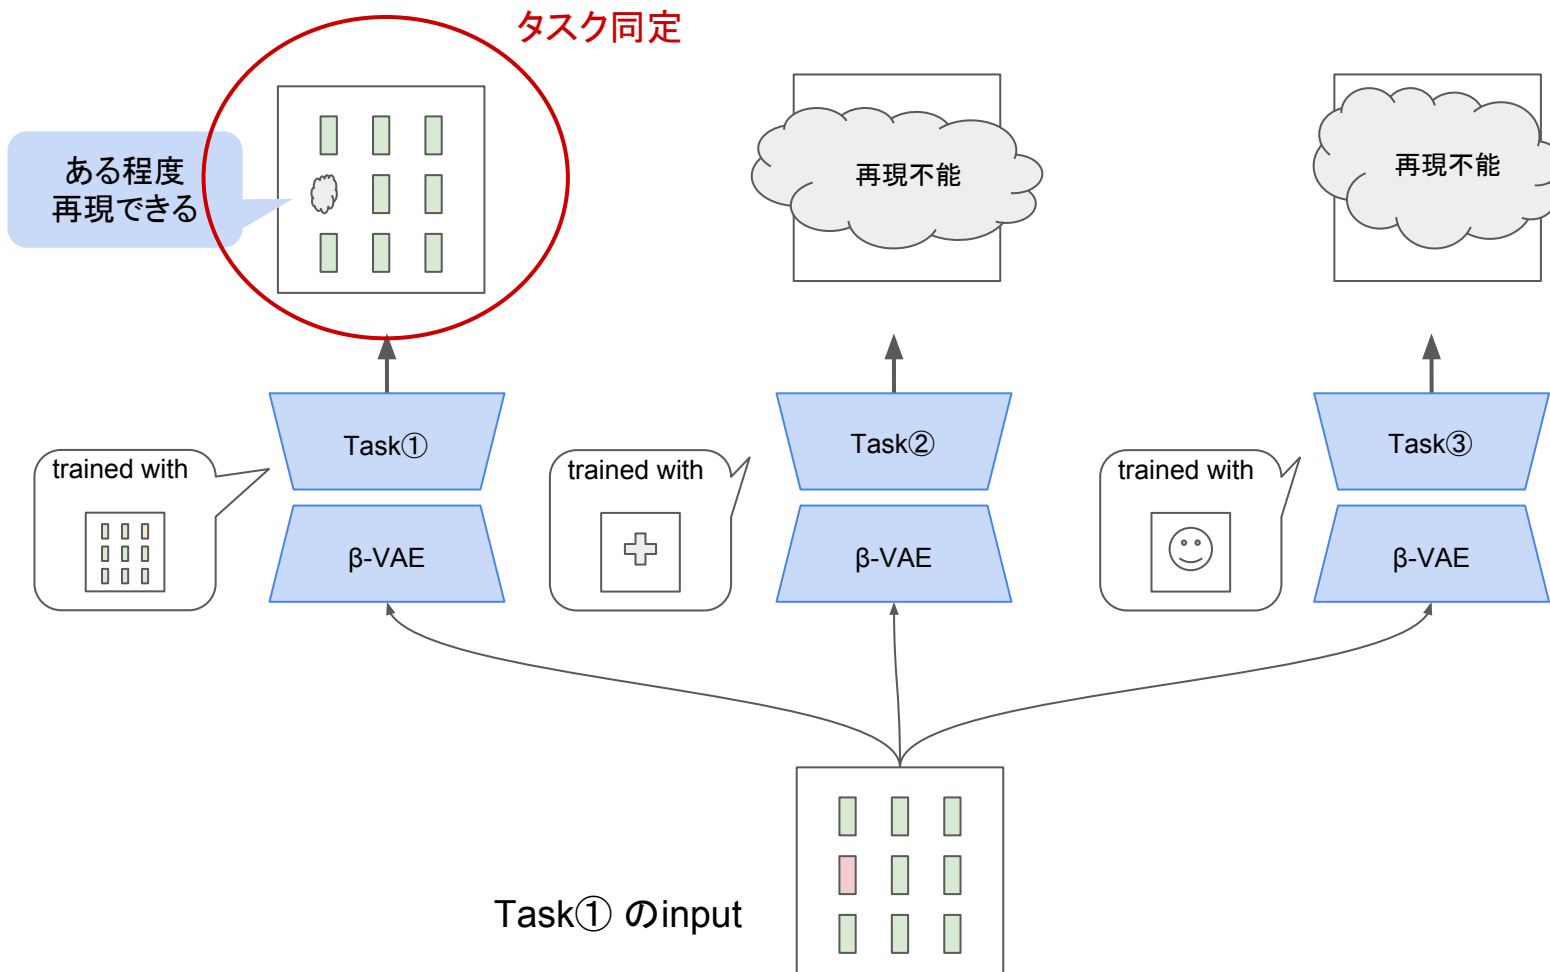
disentangleに特徴を捉えることができる



提案①: β -VAEによるサリエンシーの取得



提案②: β -VAEによるタスクスイッチング



Architecture

視覚処理部

作業記憶部

行動生成部

タスクスイッチング部

行動学習部

視覚処理部

- β -VAEをVisual Cortex (VC)に配置
 - 幼児期の自己組織化的な視野獲得との関連
- 各モジュールにおいて β -VAEの再構成誤差を利用
 - Predictive Codingとの関連
 - PFCではタスクスイッチング
 - FEFではサリエンシーマップ
 - BGでは潜在変数を入力として

行動学習部

- PPO [Schulman+ 17] をBasal Ganglia (BG)に配置

Architecture

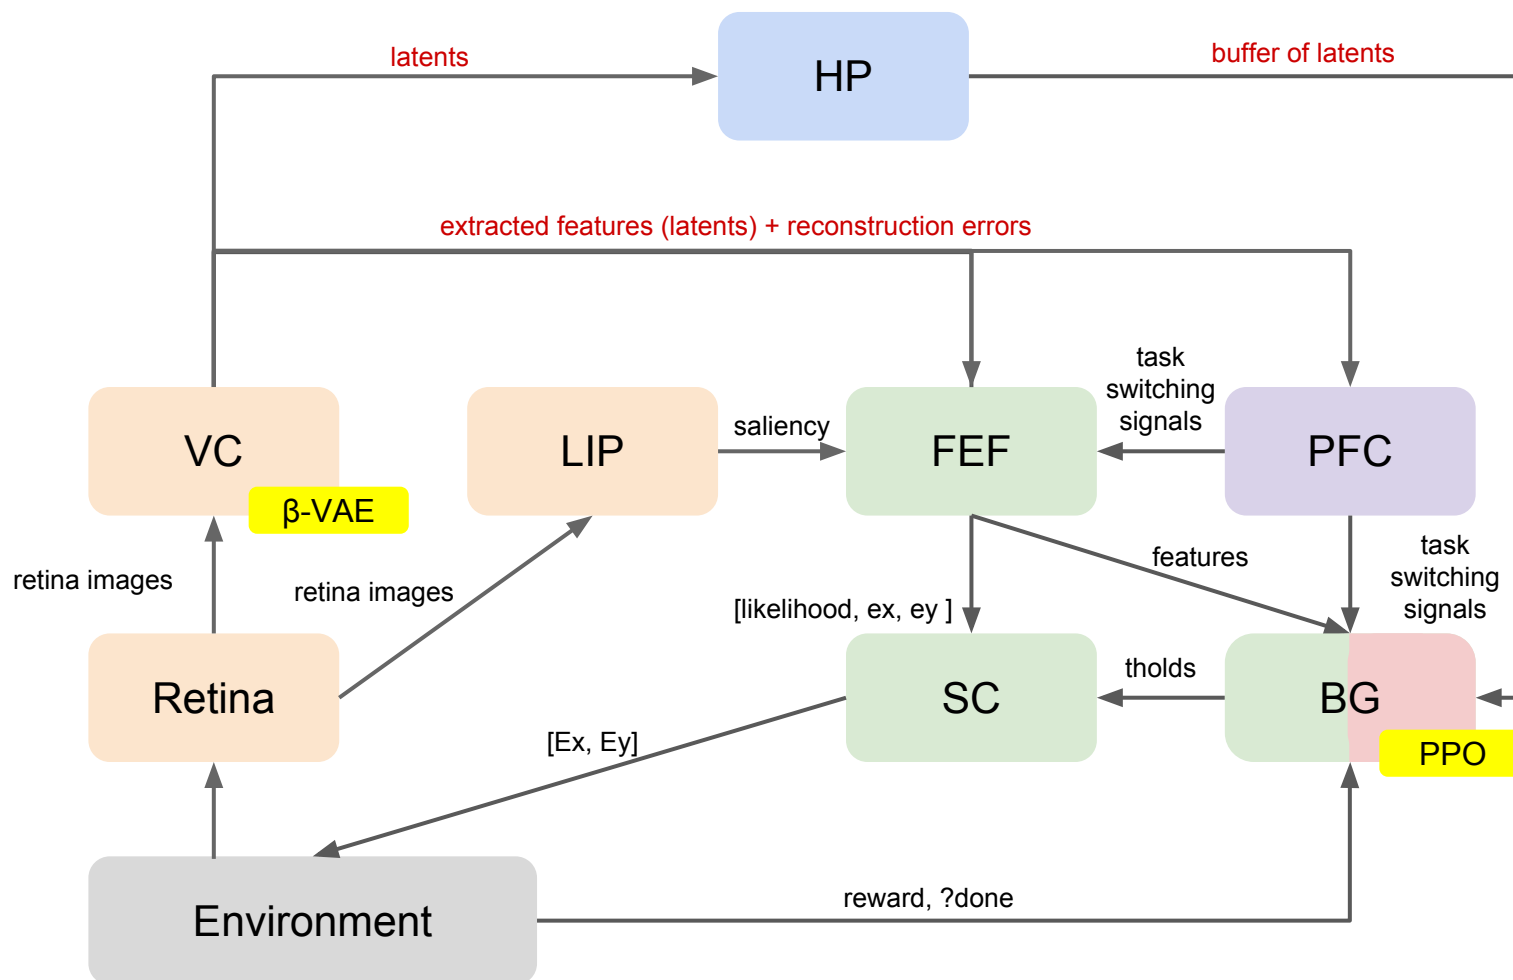
視覚処理部

作業記憶部


行動生成部

タスクスイッチング部

行動学習部



視覚処理部(Retina, VC, LIP)




- LIP

- 目的
 - FEFに画像のsaliencyを渡す
- 役割
 - Retinaから画像を受け取り、FEFにsaliencyを出力する


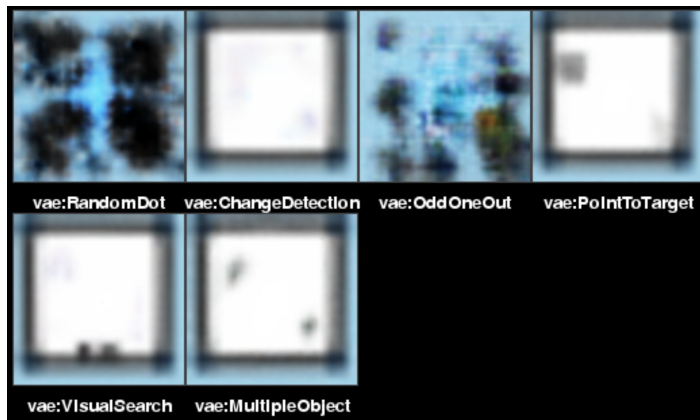
- VC

- 目的
 - disentangleな特徴抽出をする
 - 再構成誤差をsaliencyとして利用する
- 役割
 - Retinaから画像を受け取り、 β -VAE[Higgins14, 17]で FEF・HP・PFCに潜在変数と再構成誤差を出力する





β -VAEによるSaliencyの取得

現在のタスクの再構成誤差の上位10%を選択
盤面など常にあるものは再構成しやすいので再構成誤差が小さくなる




作業記憶部(HP)

- HP
 - 目的
 - 時系列遷移をBGが扱えるようにする
 - 役割
 - VC(β -VAE)から潜在変数を受けとり、過去7フレーム分をまとめてBGに出力する



タスクスイッチング部(PFC)



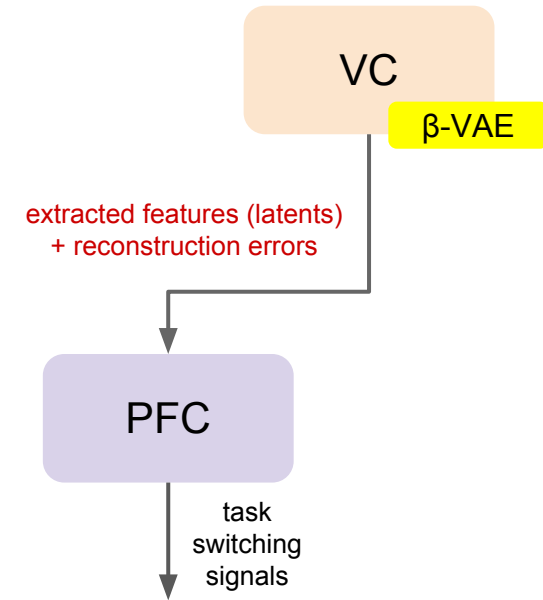
- PFC

- 目的

- FEFとBGにタスクスイッチ信号を渡す

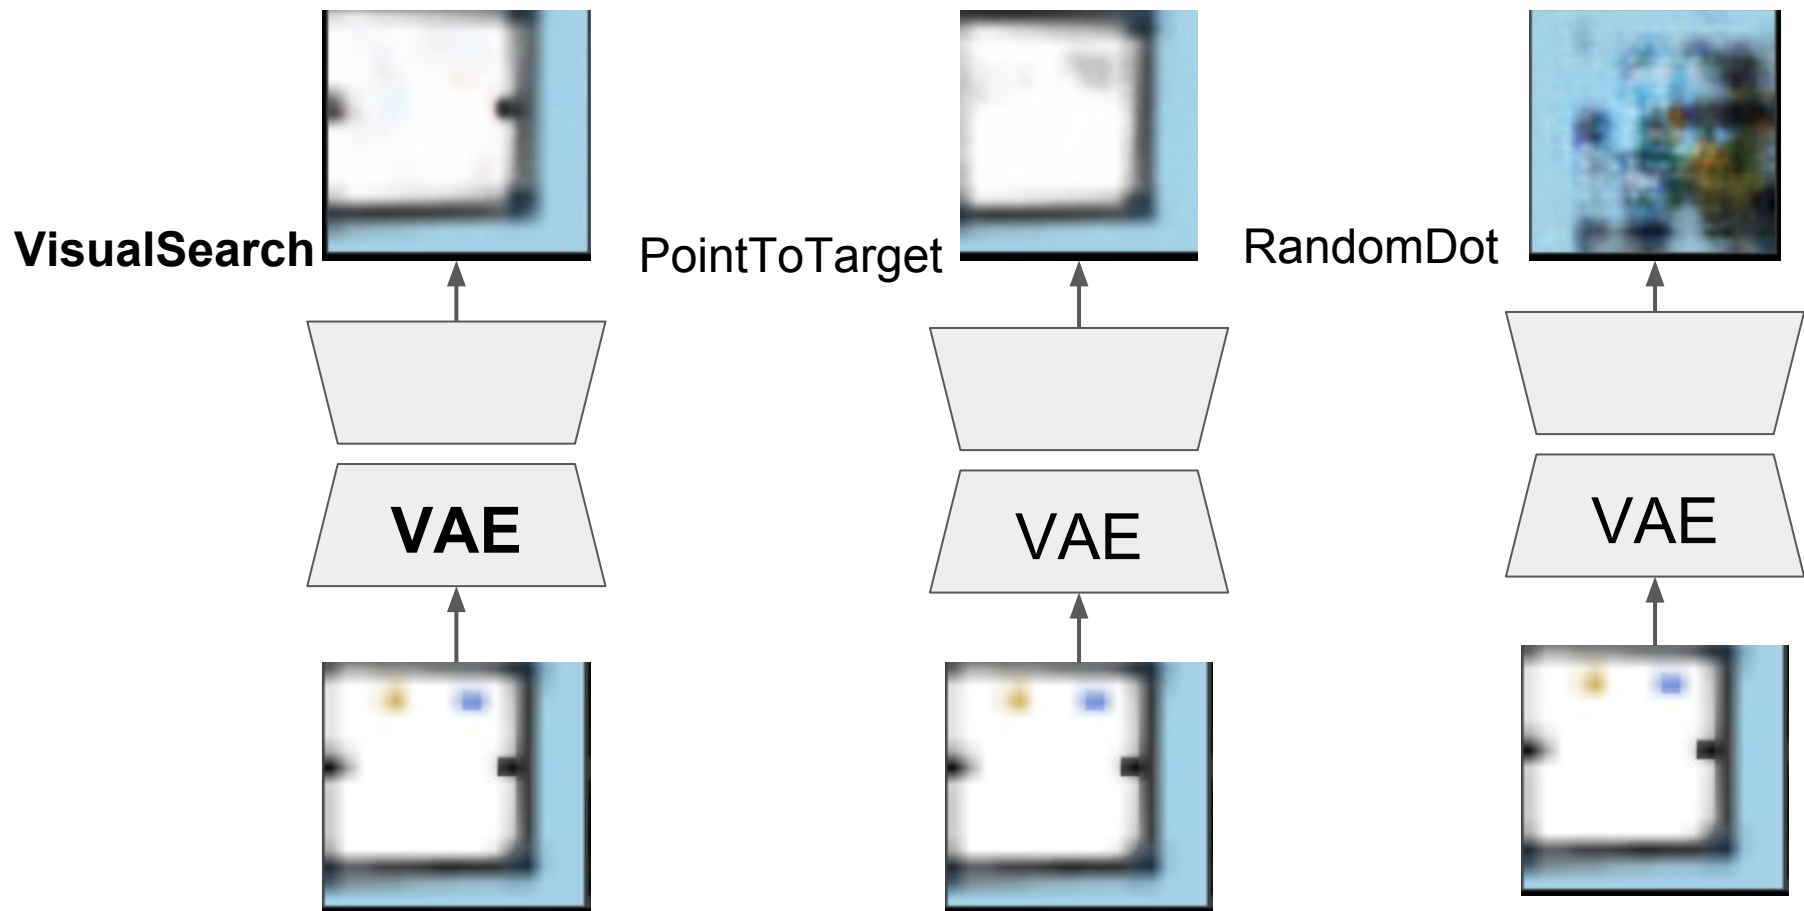
- 役割

- VC(β -VAE)から再構成誤差を受けとり、FEFとBGにタスクスイッチ信号を出力する
 - タスクスイッチ信号
 - タスクの種類
 - fixationモードかtargetモードか




β -VAEによるタスクスイッチング

VAEの再構成誤差がもっとも小さいものでタスクを決定



評価時の学習済みPPOのスイッチング

各タスクで学習したPPOをVAEのタスクスイッチングで切り替える




VAEによるfixationの判定

タスクの推定が一貫しない場合にfixationとする

Accumulatorニューロンの計算モデル[1]を用いて信頼度を計算

PointToTarget... VisualSearch.... ChangeDetection...?



推定されなかったタスク τ の信頼度

$$A_t^\tau = \alpha A_{t-1}^\tau$$

推定されたタスク τ の信頼度

$$A_t^\tau = \alpha A_{t-1}^\tau + 1.0$$


信頼度

割引率


[1] Osawa, Masahiko, Yuta Ashihara, Takuma Seno, Michita Imai, and Satoshi Kurihara. "Accumulator based arbitration model for both supervised and reinforcement learning inspired by prefrontal cortex.", ICONIP 2017.

タスクスイッチングデモ

全ての環境で教師なしタスクスイッチングが可能



行動生成部(FEF, SC, BG)



- FEF

- 目的

- 視覚情報を統合し行動に紐付ける

- 役割

- LIPからsaliencyを、VC(β -VAE)から潜在変数と再構築誤差を、PFCからタスクスイッチ信号を受け取り、BGに統合された視覚情報を、SCに行動と尤度の組を出力する

- BG(次スライド)


- SC

- 目的

- 行動を出力する

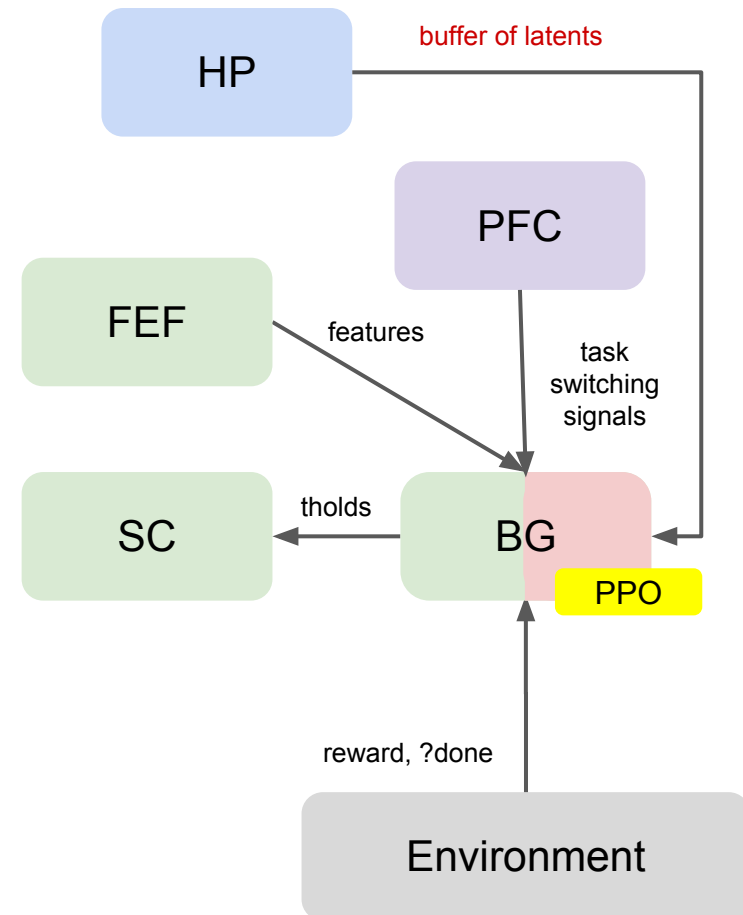

- 役割

- FEFから行動と尤度の組を、BGから尤度の閾値を受け取り、行動を出力する



行動学習部(BG)

- BG
 - 目的
 - 適切な行動のための閾値を学習する
 - 役割
 - FEFから統合された視覚情報を、HPからVC(β -VAE)の潜在変数過去7フレーム分を、PFCからタスクスイッチ信号を受け取りそれらを入力として、行動のための閾値をSCに出力する関数をPPOによって学習する



Summary

視覚処理部

作業記憶部

行動生成部

タスクスイッチング部

行動学習部

特徴抽出部

- β -VAEをVisual Cortex (VS)に配置
- 各モジュールにおいて β -VAEの再構成誤差を利用
 - PFCではタスクスイッチング
 - FEFではサリエンシーマップ
 - BGでは潜在変数を入力として

行動学習部

- PPO [Schulman+ 17] をBasal Ganglia (BG)に配置

学習の流れ

1. 各タスクにおいてVAEの学習

タスク毎に経験を集めて β -VAEの教師なし学習を行う

2. タスクの強化学習

学習済み β -VAEを用いて各タスクを個別にPPOの学習を行う

3. 評価

学習済みPPOと学習済みVAEを使って全ての課題を解く

実装面における工夫

- Interactive.shの改良 (demo)
 - 別プロセスで学習を回すことで高速に学習が見れるようになった
 - フロントからのリクエストを整理した
 - 追加情報の表示
 - スレッシュホールド, 追加したセイレンシーマップ
 - タスクスイッチの状態等
- その他
 - nvidia-dockerの整備
 - nvidia-driverをインストールしていればすぐにgpu環境に！

実験 Experiments

β -VAEの事前学習

- 各タスク毎に100ステップx1000エピソードの画像から学習
- バッチサイズ64xエポック400 (retinaの再構成に多くのステップが必要)

各タスクの学習

- 全タスクに渡って同じハイパーパラメータを使用
- PPOの学習を100万ステップ行う

評価

- 学習済みモデルを組み合わせて1つのモデルでタスクを行う

実験結果

タスク・難易度・獲得報酬の表


タスク	難易度	報酬
Point To Target	0	12
Point To Target	1	2
Point To Target	2	0
Change Detection	0	2
Change Detection	2	0
Change Detection	4	0
Odd One Out	-1	0
Random Dot	0	0

タスク	難易度	報酬
Random Dot	2	1
Random Dot	5	1
Multi Object Tracking	0	0
Multi Object Tracking	2	0
Multi Object Tracking	5	0
Visual Search	0	0
Visual Search	2	0
Visual Search	4	0

Task 1: Point to Target

背景が白


背景が黒





Reconstructの
誤差上位10%



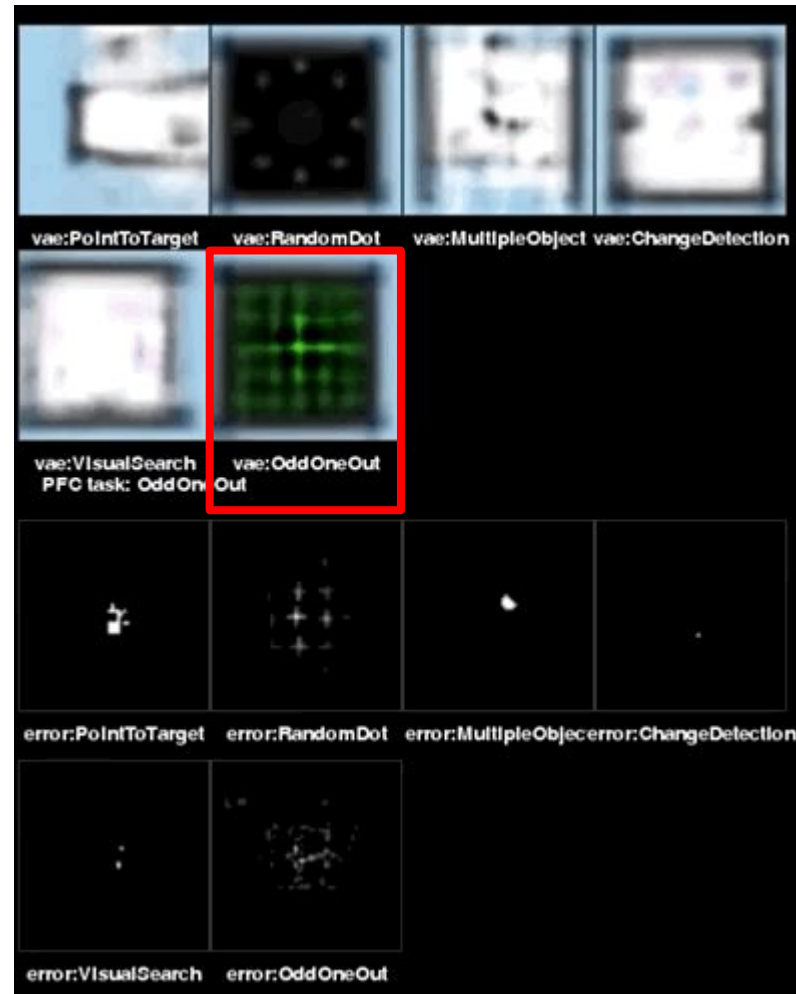

Task 2: Change Detection




Task 3: Visual Search



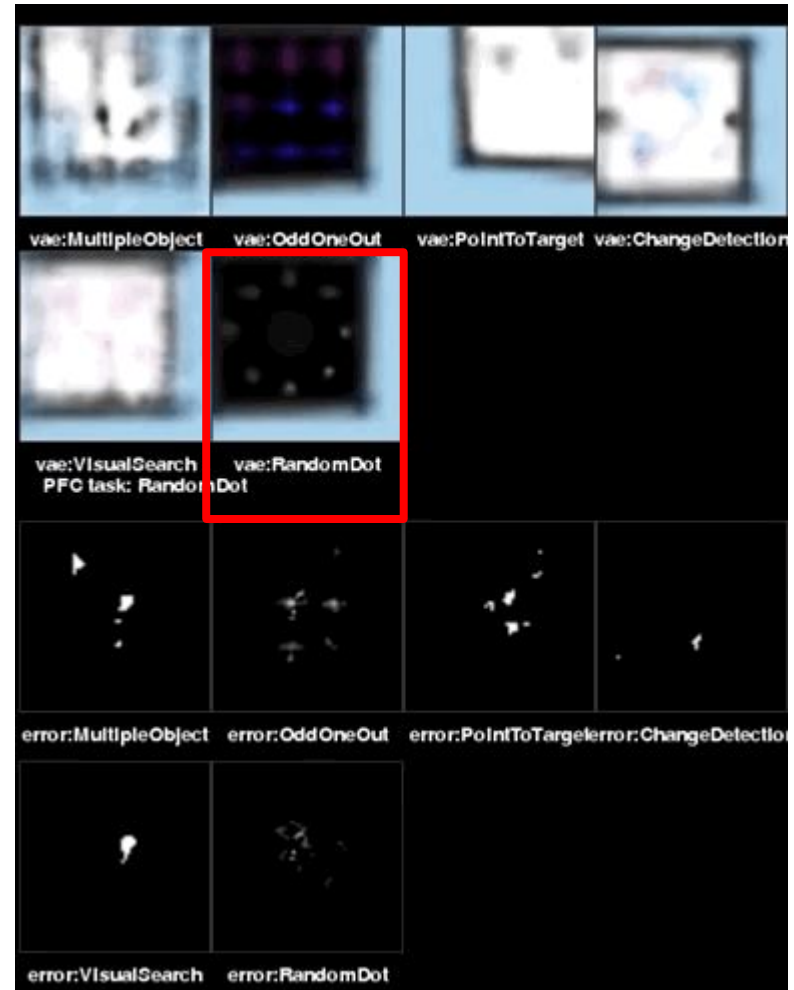

Task 4: Odd One Out



Task 5: Multiple Object Tracking

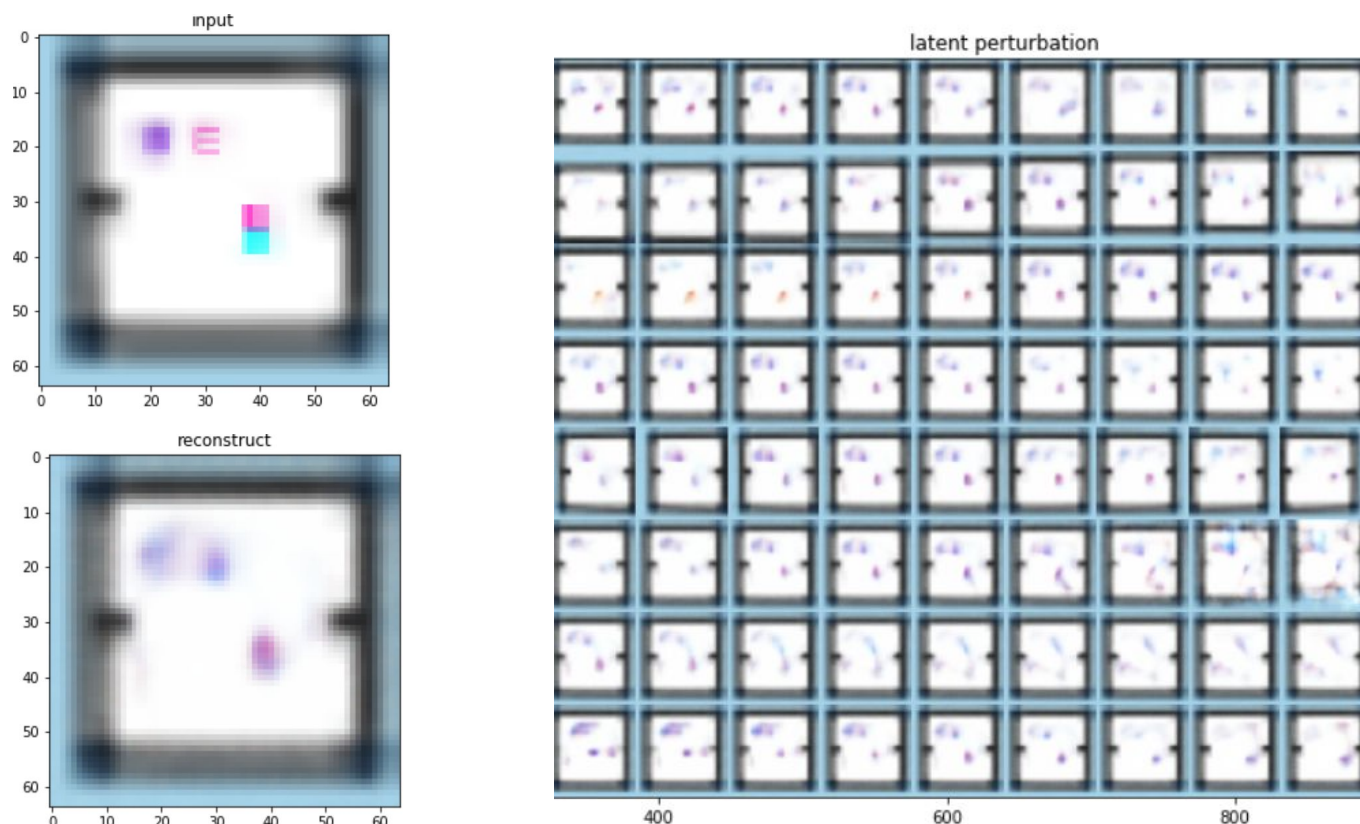


Task 6: Random Dot Motion Discrimination



考察: retina画像の再構成


β -VAEの特徴量に基づいてSaliencyを計算すればできると思っていたが...
そもそもretinaの画像が想像以上に再構成するのが難しかった



考察: タスクスイッチングの精度

Evaluationでは90%の精度だったものと10%以下だったものとに別れた


Fixationに詰まったり, 外に外れ続けてしまうと低下してしてしまった
→ 詰まった時のリカバリー方法をもっと検討すべき



反省点

ヒューリスティックの排除に固執し過ぎてしまった...

ヒューリスティックな方策でスコアをあげてもよかった




AGI \wedge

Scalability: VAEによるcontinual learning

VAEで再構成できない環境に対して**新しい重みを逐次的に学習**


→ 継続的に新しい環境を**一段高いdisentangling**で学習することが可能




Interpretability: 強化学習器の説明可能性

再構成や特徴量から強化学習器がどんな方策を獲得したのかがわかる

このVAEはvisualsearchを
学習しているようだ



このPPOはvisualsearchの
方策である



Generally Plausible: 汎用知能へ


Unsupervised
Learning



Continual Learning



Interpretability



Artificial General Intelligence

Thank you!

References

- Hackathonリポジトリ
 - <https://github.com/imai-laboratory/wba-hack2018>
 - 学習データセット等はscriptでダウンロードできます

References

- [Higgins+ 14] Higgins, I., Matthey, L., Glorot, X., Pal, A., Uria, B., Blundell, C., ... & Lerchner, A. (2016). Early visual concept learning with unsupervised deep learning. arXiv preprint arXiv:1606.05579.
- [Higgins+ 17] Higgins, I., Matthey, L., Pal, A., Burgess, C., Glorot, X., Botvinick, M., ... & Lerchner, A. (2017). beta-vae: Learning basic visual concepts with a constrained variational framework. In International Conference on Learning Representations.

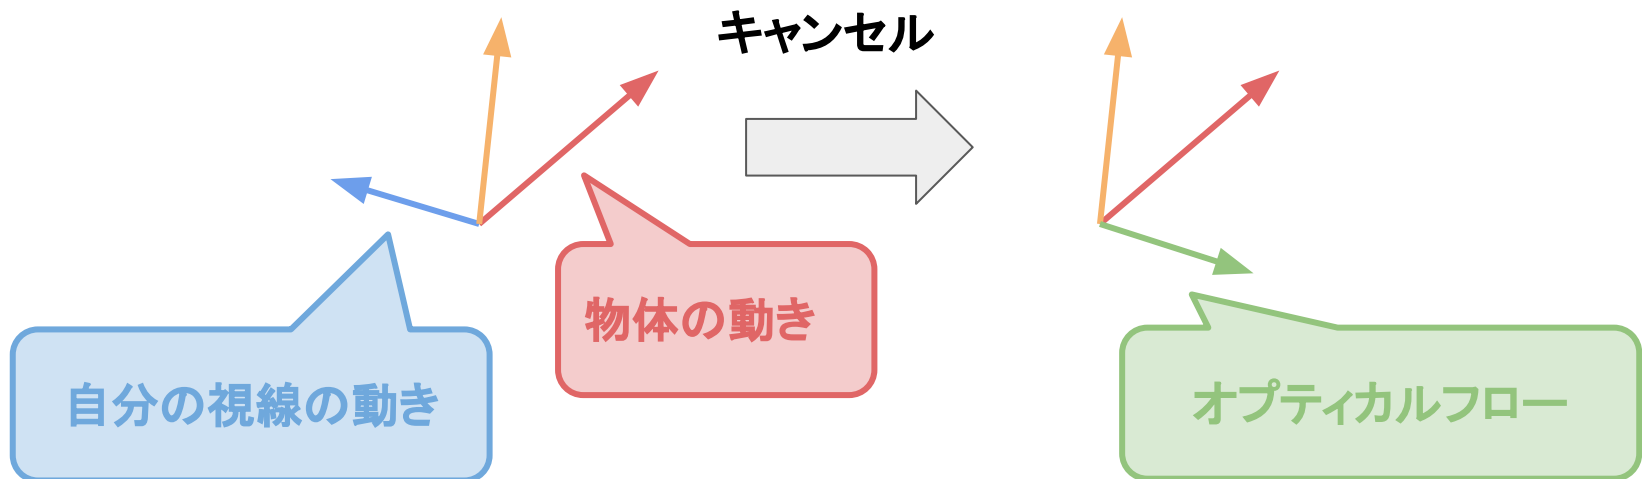


APPENDIX

オプティカルフローの計算

- 物体の動きを考えると、自分の視線の動きの影響が含まれる

⇒ 自分の視線のオプティカルフローを計算することにより、自分の視線の動きの影響を抑える



| β -VAE

| β -VAE

方針

- 基本方針
 - 各メンバの知見を生かしてつくる全脳アーキテクチャ
- 前提条件
 - 海馬アーキテクチャの研究をしている
 - 前頭前野 Accumulatorの研究をしている
 - 生成モデルの研究をしている
- 注力したい部分
 - VCでのdisentangleな特徴抽出 (生成モデル)
 - BG <-> PFCのコネクションの設計 (PFCでの強化学習)
 - HPでのワーキングメモリの実装 (DND等)

これまでの進捗

- 環境整備
 - interactive.shのフロントエンド改造
 - 爆速実行
 - 使用マシンにnvidia-dockerの整備
- アルゴリズム
 - 教師なし学習アルゴリズムのoculoenvでの検証
 - (既存の実装は微妙なので)PPOのフルスクラッチ実装
- タスク
 - 手始めにPoint to Targetの学習

これからのスケジュール

- (1日目)
 - 学習データセットの収集
 - 各モジュールにおけるアーキテクチャの実装
 - 個別タスクの学習
- (2日目)
 - モジュールの結合
 - 各タスクの学習
 - スライドづくり
- (3日目)
 - 睡魔と闘いながら発表する

